Análisis y Visualización de Datos de Ventas del Sector Retail

PIM3 Data Science

TechCore — Consultora DataVision Analytics

---

1. Contexto del proyecto

TechCore es una cadena de tiendas minoristas especializada en la venta y distribución de computadores de todas las gamas. Como parte de este reto técnico, se asume el rol de Analista de Datos Junior contratado por DataVision Analytics para centralizar y analizar la información de ventas de TechCore a nivel nacional.

El objetivo general fue transformar datos crudos de facturación en información estructurada, construir un modelo relacional, y desarrollar un dashboard interactivo en Power BI que permita extraer conclusiones estratégicas para el negocio.

El proyecto se desarrolló en 3 fases (avances), usando Power BI (Power Query), Python (pandas) y Power BI (DAX y visualización) respectivamente.

2. Estructura del proyecto

```
ProyectoM3_NombreEstudiante/
  Notebooks/
    Avances/
      Avance_1/
        Avance_1_Limpieza_Transformacion.pbix
        ventas.csv
        ventasTransformed.csv
      Avance_2/
        Avance_2_Modelo_Relacional.ipynb
        modeloVentas.xlsx
      Avance_3/
        Avance_3_Dashboard_Interactivo.pbix
  Documentacion/
    README.pdf / README.md
    Conclusiones_Recomendaciones.pdf
```

3. Avance 1 — Limpieza y transformación de datos (Power BI / Power Query)

Tech stack: Power BI Desktop, Power Query

Pasos realizados:

1. Se importó el dataset crudo de facturación (ventas.csv, 30,307 filas) a Power BI mediante Power Query.

2. Se estandarizaron nombres de columnas y tipos de datos (fechas de texto a formato date, montos a decimal number).

3. Se detectaron y corrigieron inconsistencias de captura:

- Nombres de marcas mal escritos (por ejemplo "Aple" → "Apple", "Del" → "Dell", "Lenvo" → "Lenovo", "Microsofft" → "Microsoft", "Azus" → "Asus", "Samsng" → "Samsung", "Acr" → "Acer").
- Nombres de ciudades y sucursales con variaciones de mayúsculas/tildes (por ejemplo "medellín" / "Medellín" / "MEDELLÍN" → "Medellín").

4. Se normalizó el formato de fecha y hora (de texto a tipo fecha/hora reales).

5. Se agregaron columnas derivadas de apoyo (Año, Mes, Mes y Año) directamente en Power Query.

6. Se exportó el dataset limpio como ventasTransformed.csv, listo para ser consumido en Python (Avance 2).

Archivo entregado: Avance_1_Limpieza_Transformacion.pbix, ventasTransformed.csv

4. Avance 2 — Modelo relacional (Python)

Tech stack: Python, pandas, numpy

Pasos realizados:

1. Se cargó el dataset limpio (ventasTransformed.csv) en un notebook de Jupyter.

2. Se normalizaron tipos de datos (fechas y horas a datetime, montos a float).

3. Se identificaron las entidades del modelo relacional y se generaron las 7 tablas siguientes, cada una con su clave primaria (ID autogenerado) y, donde aplica, sus claves foráneas:

Tabla	Descripción	Columnas
Sucursales	Sucursales de TechCore	SucursalID, SucursalNombre, CiudadID
Ciudades	Ciudades donde opera TechCore	CiudadID, CiudadSucursal
Vendedores	Vendedores que atendieron cada venta	VendedorID, VendedorNombre
Clientes	Clientes únicos identificados	ClienteID, ClienteNombre, GeneroCliente, EdadCliente, TelefonoCliente, EmailCliente, DireccionCliente
Productos	Catálogo único de productos vendidos	ProductoID, Nombre, Marca, Precio
Facturas	Una fila por venta (encabezado)	FacturaID, Fecha, SucursalID, ClienteID, VendedorID
DetalleFacturas	Una fila por línea de producto vendido	DetalleID, FacturaID, ProductoID, Cantidad, Descuento

4. Se transformó el dataset original (que tenía hasta 3 productos por venta "en formato ancho", en columnas repetidas) a formato largo, generando una fila por cada línea de producto vendido.

5. Se detectó y corrigió un caso de inconsistencia de datos: dos registros de un mismo producto con nombre y precio idénticos pero marca mal escrita ("Razor" vs. "Razer"), evitando así duplicar el ProductoID.

6. Se resolvió un caso de ambigüedad de clientes con el mismo nombre pero datos distintos (personas diferentes), cruzando por el conjunto completo de atributos del cliente en vez de solo el nombre.

7. Se validó la integridad referencial de las 6 relaciones del modelo (que ninguna clave foránea quedara "huérfana"). Resultado: 0 registros huérfanos en las 6 relaciones.

8. Se generaron 2 reportes exploratorios rápidos en Python: ventas totales por marca, y top 10 de productos más vendidos por unidades.

9. Se exportaron las 7 tablas como hojas separadas de un único archivo Excel: modeloVentas.xlsx, listo para alimentar el modelo de datos de Power BI en el Avance 3.

Archivo entregado: Avance_2_Modelo_Relacional.ipynb, modeloVentas.xlsx

5. Avance 3 — Dashboard interactivo (Power BI)

Tech stack: Power BI Desktop, DAX

Pasos realizados:

1. Se importó modeloVentas.xlsx a Power BI (Obtener datos → Excel), cargando las 7 hojas como tablas del modelo de datos.

2. Se verificaron las relaciones autodetectadas por Power BI entre las 7 tablas, confirmando cardinalidad (1 a muchos) y dirección de filtro correctas en las 6 relaciones del modelo.

3. Se incorporó la columna MetodoPago (no incluida en el modelo relacional del Avance 2, por no ser requerida en ese momento) mediante Power Query, cruzando el CSV original con la tabla Facturas a través de FacturaID.

4. Se crearon las jerarquías de navegación solicitadas:

- Fecha → Año → Mes → Día (usando columnas calculadas Año, Mes, NumeroMes, Dia derivadas de Facturas[Fecha], con la columna Mes ordenada cronológicamente mediante NumeroMes).
- Ciudad → Sucursal (usando RELATED() para traer el nombre de la ciudad a la tabla Sucursales, dado que Power BI Desktop requiere que las columnas de una jerarquía pertenezcan a la misma tabla).

5. Se crearon las siguientes medidas DAX:

Medida	Fórmula (resumen)	Descripción
VentasTotales	SUMX de Cantidad × Precio × (1 − Descuento)	Ventas netas, después de descuento
VentasBrutas	SUMX de Cantidad × Precio	Ventas a precio de lista, sin descuento
Margen	VentasBrutas − VentasTotales	Monto cedido en descuentos
%Margen	DIVIDE(Margen, VentasBrutas)	Margen como % de las ventas brutas
CantidadFacturas	DISTINCTCOUNT(Facturas[FacturaID])	Número de ventas únicas
TicketPromedio	DIVIDE(VentasTotales, CantidadFacturas)	Monto promedio gastado por compra
ProductosVendidos	SUM(DetalleFacturas[Cantidad])	Unidades totales vendidas
%ParticipacionCiudad	DIVIDE(VentasTotales, CALCULATE(VentasTotales, ALL(Ciudades)))	Participación de cada ciudad sobre el total

6. Se implementaron 5 segmentadores dinámicos: Ciudad, Marca de producto, Método de pago, Rango de fechas (estilo "Entre") y Rango de edad del cliente (estilo "Entre"), más un botón de reinicio de filtros.

7. Se construyeron las visualizaciones interactivas solicitadas:

- Mapa geográfico de burbujas: ventas totales por ciudad.
- Gráfico de barras: ventas totales por marca de producto.
- Gráfico de líneas: evolución de ventas totales por Año/Mes/Día (con drill-down habilitado mediante la jerarquía de fecha).
- 4 tarjetas de KPI: Ventas Brutas, Ventas Totales (Netas), Ticket Promedio y Total de Productos Vendidos.

8. Se aplicó un tema de color personalizado y se reorganizó el lienzo en franjas (segmentadores arriba, tarjetas KPI en el centro, gráficos de detalle abajo) para un diseño claro y orientado a la acción.

Archivo entregado: Avance_3_Dashboard_Interactivo.pbix

6. Hallazgos principales

- Medellín es la ciudad con mayor volumen de ventas totales de las 4 ciudades analizadas (Bogotá, Cali, Medellín, Pereira).
- Lenovo es la marca líder en ventas de forma consistente en las 4 ciudades, seguida por HP, Dell y Apple.
- Se identificó una caída considerable en ventas entre 2024 y 2025, la más marcada de toda la serie histórica (2015–2025).
- Tarjeta de Crédito es el método de pago más utilizado, concentrando cerca de un tercio del total de ventas.
- El segmento de clientes de 18 a 30 años es el más activo en volumen de compra, por encima de los segmentos de 31–40 y 41–51 años.

El detalle completo de estos hallazgos, junto con las recomendaciones estratégicas derivadas, se encuentra en el documento Conclusiones_Recomendaciones.

7. Cómo reproducir el proyecto

1. Abrir Avance_1_Limpieza_Transformacion.pbix en Power BI Desktop para revisar los pasos de limpieza aplicados en Power Query (o partir directamente de ventasTransformed.csv).

2. Abrir Avance_2_Modelo_Relacional.ipynb en Jupyter y ejecutar todas las celdas en orden; esto regenera las 7 tablas del modelo y exporta modeloVentas.xlsx.

3. Abrir Avance_3_Dashboard_Interactivo.pbix en Power BI Desktop. Si se desea regenerar el modelo de datos desde cero, usar Obtener datos → Excel apuntando a modeloVentas.xlsx, y repetir la configuración de relaciones, jerarquías, medidas DAX y visuales descrita en la sección 5.